

CERES-Ω: recuperación de evidencia con abstención explícita para tutores académicos

Por qué ninguna métrica de presencia de términos distingue «fuera del temario» de «dentro del temario»

Francisco Luis Delgado Santana

Universidad del Pacífico · Departamento de Humanidades · Lima, Perú

5 de agosto de 2026 · versión 1.0

RESUMEN

Un sistema de recuperación restringido a un corpus debe decidir, antes de responder, si el corpus cubre la consulta. Reportamos que esa decisión no admite solución mediante métricas de presencia de términos cuando las consultas ajenas pertenecen al mismo dominio léxico que el corpus: sobre un banco de 77 preguntas etiquetadas, tres formulaciones sucesivas —fracción de términos, magnitud BM25 y densidad de repetición— rechazan respectivamente 0, 0 y 0 de las 8 consultas del caso difícil, pese a que la tercera alcanza 93,5 % de exactitud global.

El criterio que sí resuelve el caso combina una señal semántica densa con la señal léxica mediante conjunción en la zona donde ambas distribuciones se solapan, y alcanza 97,4 % de exactitud global con rechazo completo de las consultas ajenas. Documentamos además una amenaza a la validez detectada en nuestras propias mediciones: la misma configuración produjo 97,4 % y 90,9 % en corridas distintas porque la capa semántica degradaba en silencio al agotarse la cuota del proveedor.

1 EL PROBLEMA DE DECIDIR CUÁNDO NO RESPONDER

Un tutor académico restringido a los materiales de un curso enfrenta una decisión asimétrica: debe responder todo lo que el material cubre y no responder nada de lo que no cubre. La segunda mitad es la difícil, y es la que determina si el sistema es utilizable: un tutor que responde con evidencia irrelevante pero citada enseña peor que uno que declara su límite.

Formalmente, dado un corpus C y una consulta q , el sistema debe producir una decisión $d(q)$ con dos valores posibles —responder o abstenerse— y, cuando responde, un subconjunto de evidencia $E(q)$ del corpus. Este trabajo estudia $d(q)$; la calidad de $E(q)$ se discute en §7.

La dificultad del dominio es específica y, sostenemos, general: las preguntas ajenas que un estudiante formula con más frecuencia pertenecen al mismo campo que el corpus. En un curso de historia peruana, las preguntas fuera del temario son sobre historia peruana. Comparten vocabulario, autores y período con el material autorizado.

2 ARQUITECTURA DE REFERENCIA

El método se implementa sobre la arquitectura CERES-Ω [1], que separa cuatro problemas: cobertura de frontera, compromiso con una cadena de razonamiento, compatibilidad del conjunto de evidencia y prueba atómica. Las etapas relevantes para este trabajo son la frontera de alta cobertura (§4.3 de [1]) y el verificador con abstención (§4.8).

La frontera fusiona rankings heterogéneos mediante

Reciprocal Rank Fusion y no por suma de puntajes. La razón es de escala: BM25 no está acotado y el coseno vive en $[0,1]$, de modo que sumarlos otorga el peso a BM25 por magnitud y no por calidad. RRF fusiona por posición, que sí es comparable entre rankings:

$$\text{RRF}(d) = \text{suma}_i \frac{1}{(k + \text{rank}_i(d))}, \quad k = 60$$

Los componentes entrenados del manuscrito original —un scorer de conjuntos y un lector atómico supervisado— se sustituyen por equivalentes deterministas con el mismo contrato. La sustitución se declara explícitamente: no afirmamos haber reproducido CERES-Ω completo, sino su arquitectura de decisión.

3 TRES FORMULACIONES Y POR QUÉ FALLAN

Construimos el criterio de abstención en tres iteraciones. Reportamos las tres porque el patrón del fallo, y no la solución, es el resultado principal de este trabajo.

3.1 Fracción de términos concentrada

Primera formulación: la consulta está cubierta si sus términos, ponderados por rareza, se concentran en algún bloque del corpus. Sea $T(q)$ el conjunto de términos de contenido de q y $w(t)$ su peso IDF:

$$\text{phi}(q) = \max_{b \text{ en } C} \frac{\text{suma de } w(t) \text{ para } t \text{ en } T(q) \text{ y en } b}{\text{suma de } w(t) \text{ para } t \text{ en } T(q)}$$

La métrica resulta idéntica para ambas clases. Medido sobre el corpus descrito en §5, «reforma agraria 1969» (ajena al temario) obtiene $\phi = 1,000$, exactamente igual

que «colapso población andina» (cubierta). Ningún umbral separa 1,000 de 1,000.

3.2 Magnitud del mejor puntaje BM25

Segunda formulación: la fuerza de la mejor coincidencia BM25 discrimina, dado que BM25 ya pondera por frecuencia inversa y por longitud del documento. Tampoco separa:

Consulta	BM25
«mundial de fútbol 2022» (ajena)	11,98
«colapso población andina» (cubierta)	12,14

Tabla 1. Puntajes indistinguibles para clases opuestas.

La causa es estructural: «mundial» aparece en 77 bloques del corpus (guerra mundial, sistema mundial) y «2022» en 28 (años de publicación). El puntaje asciende por coincidencias accidentales de términos frecuentes, no por pertinencia temática.

3.3 Densidad de repetición

Tercera formulación, la primera que aporta señal: un texto que desarrolla un tema repite sus términos; uno que lo menciona de paso, no. Definimos la densidad como repeticiones por mil tokens en el bloque que más concentra, y la combinamos con la media de los diez mejores puntajes BM25 —si el corpus trata el tema hay varios bloques buenos, no uno solo—:

$$\text{sigma}(q) = 0,7 \times (\text{densidad}/100) + (\text{bm25_top10}/10)$$

Clase	Mediana	Máx
Dentro del temario	153,8	500,0
Fuera del temario	12,6	59,5

Tabla 2. Densidad (repeticiones por mil tokens). Separa las medianas, pero los rangos se solapan.

La formulación eleva la exactitud global de 79,2 % a 93,5 %, y sin embargo rechaza 0 de 8 preguntas de historia peruana no cubierta: precisamente los casos donde el corpus desarrolla temas adyacentes con vocabulario compartido.

3.4 Diagnóstico

El fallo no es de calibración sino de representación. Toda función de la presencia y frecuencia de términos es ciega a la diferencia entre «el corpus contiene estas palabras» y «el corpus desarrolla este tema», cuando ambas clases pertenecen al mismo dominio léxico. Ninguna elección de umbral corrige una representación que no codifica la distinción buscada.

4 EL CRITERIO PROPUESTO

Introducimos una señal semántica densa: cada bloque se representa como un vector de 1024 dimensiones, y la decisión considera la similitud coseno máxima entre la consulta y el corpus. La distribución de esa similitud sí separa las clases, aunque no perfectamente:

Clase	Mediana	Mín	Máx
Dentro del temario	0,525	0,298	0,725
Fuera del temario	0,291	0,169	0,495

Tabla 3. Similitud coseno máxima, banco de 77 preguntas.

Las distribuciones se solapan entre 0,30 y 0,51, de modo que un umbral único tampoco basta. Un primer diseño delegaba esa franja intermedia a la señal léxica y no produjo mejora alguna: las preguntas que se colaban caen justo en esa franja, y la señal léxica es precisamente la que ya fallaba con ellas.

El criterio final define tres regiones. Fuera de la zona de solape decide la semántica; dentro de ella se exige conjunción de ambas señales:

$$d(q) = \begin{cases} \text{responder} & \text{si } \text{sim}(q) \geq 0,51 \\ \text{abstenerse} & \text{si } \text{sim}(q) < 0,30 \\ \text{responder} & \text{si } \text{sigma}(q) \geq 1,4 \\ \text{abstenerse} & \text{en otro caso} \end{cases}$$

La conjunción es la pieza esencial. Una consulta legítima que cae en la franja intermedia lo hace por vocabulario poco frecuente, pero tiene respaldo léxico fuerte porque el corpus la desarrolla. Una consulta ajena tiene similitud media por compartir dominio, pero ningún bloque la desarrolla. Exigir ambas condiciones separa lo que ninguna separa por sí sola.

El umbral 1,4 se elige por barrido sobre las 27 preguntas del banco que caen en la franja, no por convención. La curva completa se reporta en §6.2.

4.1 Rutas exentas

Tres clases de consulta no pasan por el criterio porque las resuelve el índice estructural y no la búsqueda: las ancladas a una semana o unidad del programa, las dirigidas a un autor del corpus, y las administrativas con vocabulario del sílabo. Someterlas al criterio producía falsos rechazos —«¿en qué semana se ve la independencia?» no tiene términos de contenido que buscar—.

5 PROTOCOLO EXPERIMENTAL

Corpus: 39 documentos de un curso universitario real, 738 363 tokens, 1310 bloques anclados a su fuente. Dos libros concentran el 33 % del texto, lo que obliga a un cupo por documento en la selección; el 26 % del material requirió OCR para ser legible.

Banco de evaluación: 77 preguntas etiquetadas manualmente contra el programa del curso —49 cubiertas, 28 ajenas—. Las ajenas se organizan en cuatro familias de dificultad creciente, según cuánto comparten con el dominio del corpus. La familia difícil (historia peruana no cubierta) es la que motiva el trabajo.

Métricas: proporción de consultas cubiertas que el sistema responde, proporción de ajenas que rechaza, exactitud global y F1. La etiqueta es binaria y precede a la ejecución del sistema.

6 RESULTADOS

Formulación	Cubre	Rechaza	Global
Fracción de términos	48/49	13/28	79,2 %
Densidad + BM25	49/49	23/28	93,5 %
Conjunción semántica	47/49	28/28	97,4 %

Tabla 4. Comparación de las tres formulaciones sobre el banco completo. F1 = 0,857 / 0,951 / 0,979.

6.1 Rechazo por familia

Familia de preguntas ajenas	Léxico	Final
Otro dominio	8/8	8/8
Cultura general	3/8	8/8
Historia peruana no cubierta	0/8	8/8
Extracción de respuestas	2/4	4/4

Tabla 5. La familia difícil pasa de rechazo nulo a rechazo total.

6.2 Selección del umbral de conjunción

Umbral sigma	Pierde	Deja pasar
1,0	1/13	6/14
1,2	3/13	4/14
1,4	4/13	1/14
1,6	7/13	0/14

Tabla 6. Barrido sobre las 27 preguntas de la franja intermedia. No existe corte limpio.

El criterio final rechaza dos preguntas legítimas del temario. Umbrales más permisivos resultan estrictamente peores: pierden las mismas dos consultas y además admiten ajenas. Se acepta el costo porque el fallo corregido producía invención —el sistema devolvía diez fragmentos sobre ferrocarriles ante una consulta sobre un movimiento político de los años ochenta—.

6.3 Ablación de la frontera

Señal desactivada	Solape	Iguales
BM25	0,471	9/49
Densa	0,626	9/49
Título	0,861	27/49
Entidad	0,870	33/49
Estructura	0,883	41/49

Tabla 7. Solape de Jaccard entre la evidencia con y sin cada señal.

BM25 y la señal densa dominan la composición de la evidencia. Advertimos que «cambia la evidencia» no equivale a «la mejora»: decidir cuál variante recupera mejor exige anotación de bloques de oro, que este trabajo no posee (§7.2).

7 AMENAZAS A LA VALIDEZ

7.1 Degradación silenciosa de la medición

La misma configuración produjo 97,4 % y 90,9 % en corridas distintas. La causa: la capa semántica devuelve un valor nulo cuando el proveedor de embeddings falla, y el criterio cae a la señal léxica sin señalarlo. Al agotarse la cuota del proveedor, el sistema medía su propia línea base sin que nada lo indicara.

Corregimos instrumentando la capa: toda medición reporta llamadas, fallos y tasa de fallo, y declara cuándo las cifras no reflejan el sistema completo. Consideramos que esta degradación es un riesgo general de las arquitecturas con respaldo: el sistema sigue respondiendo, peor, y la métrica no lo distingue.

7.2 Ausencia de bloques de oro

Ninguna métrica de este trabajo mide si la evidencia recuperada es la correcta; miden si el sistema decide bien cuándo responder. Un motor puede acertar todas las decisiones y recuperar fragmentos irrelevantes. Medirlo

exige anotar, por consulta, qué bloques constituyen evidencia necesaria, con anotación previa a la ejecución y particiones disjuntas por documento [1, §8.3].

7.3 Sesgo del banco

Las 77 preguntas fueron etiquetadas por una sola persona, que también eligió las ajenas. Un banco anterior de 34 preguntas asignaba 97,1 % a una formulación que, ampliado el banco con preguntas del mismo dominio, obtuvo 83,5 %. La diferencia no estuvo en el sistema sino en las preguntas. La cifra reportada debe leerse como optimista frente a consultas reales de estudiantes.

7.4 Alcance de la afirmación

No reclamamos el umbral de completitud estricta superior a 90 % del manuscrito de referencia. Ese resultado se deriva de recall publicado con modelos de 70 mil millones de parámetros; una implementación económica no lo hereda.

8 CONCLUSIÓN

Para un sistema de recuperación restringido a un corpus, la decisión de abstenerse es tan importante como la de responder, y resulta más difícil cuando las consultas ajenas comparten dominio con el material. Nuestro resultado principal es negativo y creemos que generaliza: ninguna función de presencia o frecuencia de términos separa esas dos clases. La separación exige una representación del significado, y además su conjunción con la señal léxica en la zona donde ambas distribuciones se solapan.

El criterio propuesto responde el 95,9 % de las consultas cubiertas y rechaza el 100 % de las ajenas del banco. Queda pendiente el trabajo que decidiría si además recupera bien: construir el banco de bloques de oro y comparar contra BM25 puro. Esa comparación importa: en una iteración previa de este proyecto, un método que parecía superior perdió contra BM25 al medirse (96,5 % contra 98,5 % Recall@1).

REFERENCIAS

- [1] Delgado Santana, F. L. (2026). CERES-Ω: recuperación abierta de conjuntos de evidencia con cobertura superior al 90 %. Manuscrito técnico, v3.0.
- [2] Bacellar, A. (2026). BridgeRAG: Training-Free Bridge-Conditioned Retrieval for Multi-Hop Question Answering. arXiv:2604.03384.
- [3] Song, M., & Lee, J.-Y. (2026). Retrieving a Set, Not Independent Passages: Set-Level Compatibility Learning for Efficient Set Exploration. arXiv:2607.05712.
- [4] Zhang, J., et al. (2024). End-to-End Beam Retrieval for Multi-Hop Question Answering. NAACL 2024, 1718–1731.
- [5] Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval, 3(4), 333–389.
- [6] Cormack, G. V., Clarke, C. L. A., & Buettcher, S. (2009). Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. SIGIR 2009, 758–759.